PEMROSESAN BAHASA ALAMI
Natural Language Processing

Pertemuan 10

Sequence-to-Sequence & Attention

Arsitektur Seq2Seq (Encoder–Decoder), Attention Mechanism, serta penerapannya pada Machine Translation, Chatbot, dan Text Generation.

NINF236023 - INTNINF236026

Dosen Pengampu: Prof. Aji Prasetya Wibawa, S.T., M.M.T., Ph.D.

M. Zainal Arifin, S.Si., M.Kom. Ph.D

Mentor: Agung Bella Putra Utama

Fadia Irsania Putri

Apa yang Akan Kita Pelajari?

Today's Topics

1. Sequence-to-Sequence (Seq2Seq)
2. Arsitektur Encoder–Decoder
3. Attention Mechanism
4. Machine Translation
5. Chatbot
6. Text Generation

Pertemuan 8: Model membaca urutan
Pertemuan 10: Model menghasilkan urutan

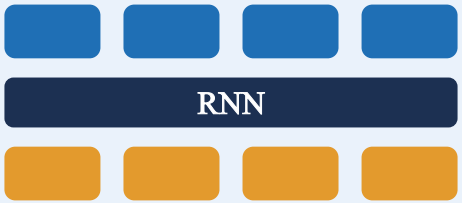
Dari Membaca ke Menulis Teks

Many-to-one



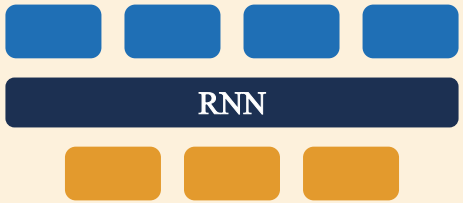
Sentimen: banyak kata → 1 label

Many-to-many sinkron



POS/NER: 1 token → 1 label

Many-to-many beda panjang



Seq2Seq: input & output bebas panjang

Masalah baru yang muncul

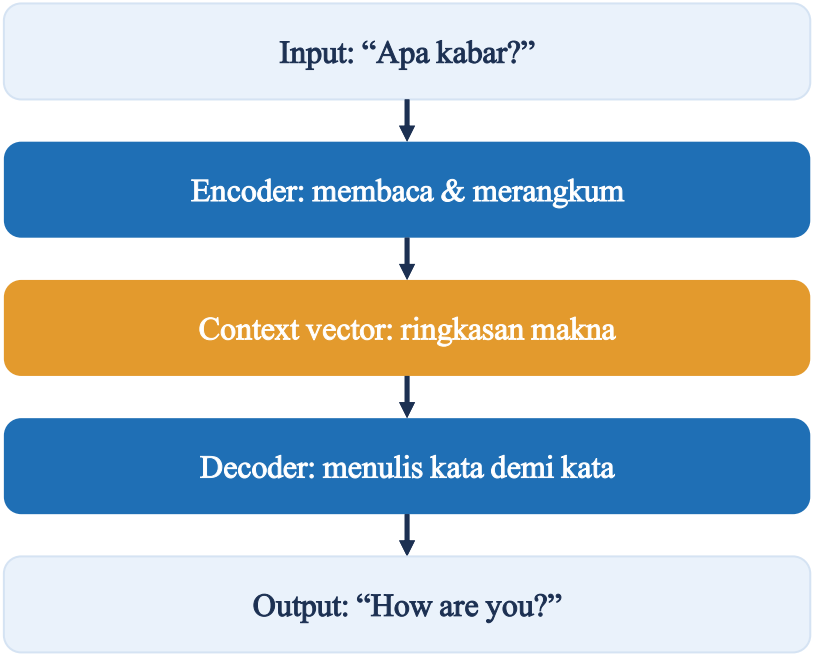
"Terima kasih banyak" (3 kata) → "Thank you" (2 kata). Panjang output tidak sama dengan input dan tidak bisa dipasangkan kata per kata.

Kita butuh model yang membaca seluruh input dahulu, baru menulis output dengan panjang bebas → **Seq2Seq.**

Apa Itu Sequence-to-Sequence?

Seq2Seq

- Model yang **mengubah satu urutan** (input) menjadi **urutan lain** (output).
- Panjang input dan output **boleh berbeda**.
- Terdiri dari dua bagian: **Encoder** dan **Decoder**.
- Dibangun dari RNN / LSTM / GRU (Pertemuan 8).
- Dipopulerkan sekitar 2014 (Sutskever dkk. dan Cho dkk.).



Analogi: penerjemah membaca seluruh kalimat lebih dulu (encoder), lalu menuliskannya dalam bahasa lain (decoder).

Penerapan Seq2Seq dalam NLP

Machine Translation

Kalimat sumber → kalimat target

Indonesia → Inggris

Chatbot / Dialog

Ucapan pengguna → respons

Pertanyaan → jawaban

Text Generation

Prompt / seed → lanjutan teks

Puisi, cerita, lirik

Summarization

Artikel panjang → ringkasan

Berita → 2 kalimat

Speech Recognition

Rekaman suara → teks

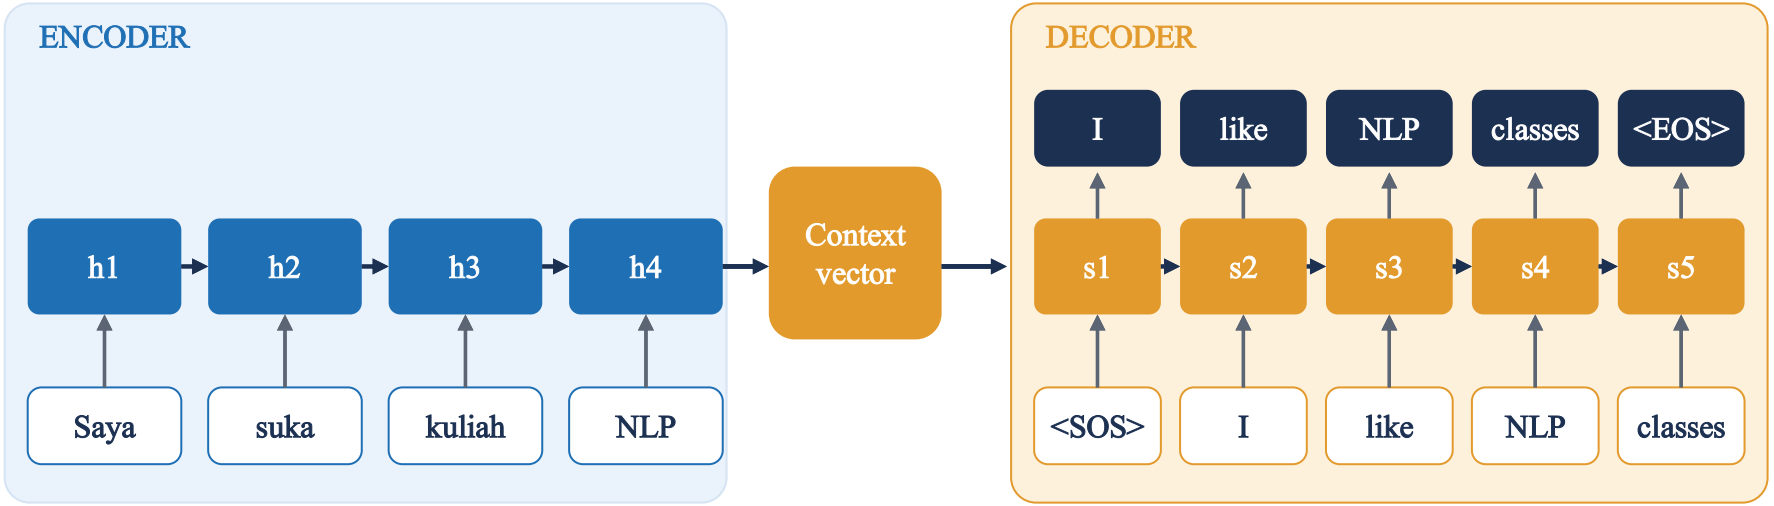
Audio → transkrip

Image Captioning

Gambar → kalimat deskripsi

Foto → caption

Arsitektur Encoder–Decoder



1 Encoder membaca

Kalimat sumber dibaca kata demi kata.

2 Context vector

Hidden state terakhir meringkas makna kalimat.

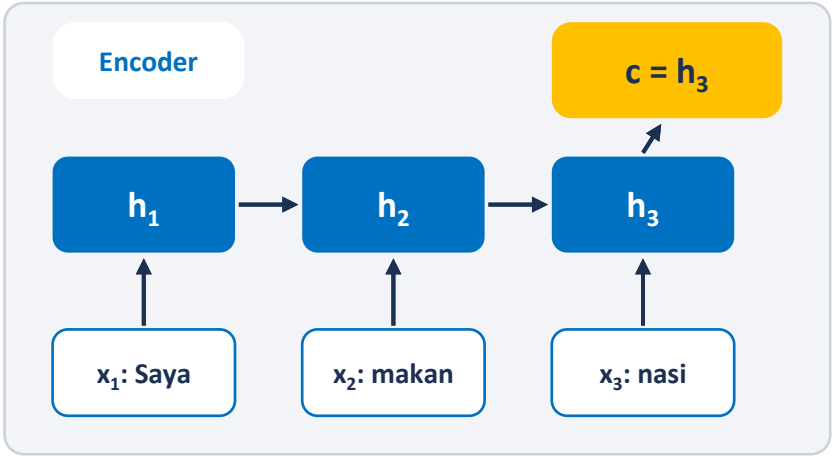
3 Decoder menulis

Kata ditulis satu per satu sampai <EOS>.

Kata yang baru dihasilkan decoder dipakai sebagai input langkah berikutnya.

Encoder

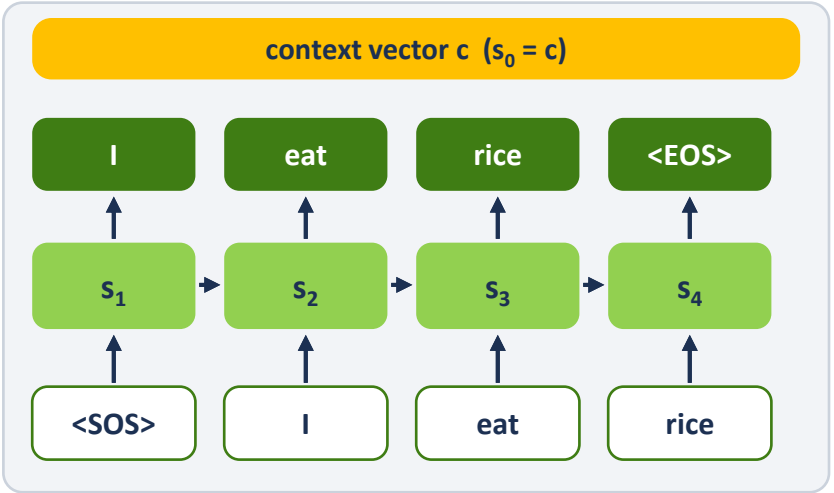
- Membaca kalimat **token demi token** (embedding → RNN / LSTM / GRU).
- Setiap langkah menghasilkan **hidden state** h_t yang membawa informasi token sebelumnya.
- Hasil akhirnya: **context vector** yang merangkum input.
- Encoder dapat berupa **BiRNN** (Pertemuan 8) agar tiap posisi memuat konteks kiri dan kanan.



Encoder = kalimat sumber diubah menjadi representasi vektor.

Decoder

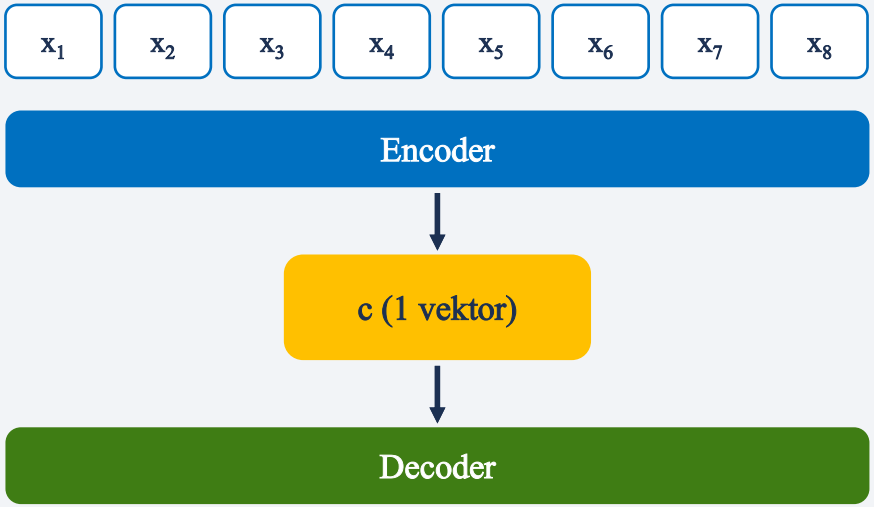
- Bersifat **autoregresif**: input langkah t adalah token keluaran langkah t−1.
- Mulai dari token **<SOS>**; state awal $\mathbf{s_0 = c}$ dari encoder.
- Tiap langkah menebak **satu kata** (softmax atas kosakata).
- Berhenti saat menghasilkan **<EOS>** atau mencapai panjang maksimum.



Token Khusus

<SOS>	<EOS>	<PAD>	<UNK>
Start of Sequence: penanda awal output	End of Sequence: penanda output selesai	Padding: menyamakan panjang batch (seperti Pertemuan 8)	Unknown: kata di luar kosakata

Keterbatasan: Bottleneck Context Vector



Kalimat panjang dipadatkan ke satu vektor berukuran tetap.

- **Seluruh informasi** kalimat harus muat dalam satu vektor.
- Semakin panjang kalimat, semakin banyak informasi (terutama bagian awal) yang hilang.
- Decoder memakai c yang **sama** di setiap langkah, tanpa tahu kata sumber mana yang relevan.
- Diperparah vanishing gradient pada urutan panjang (Pertemuan 8).

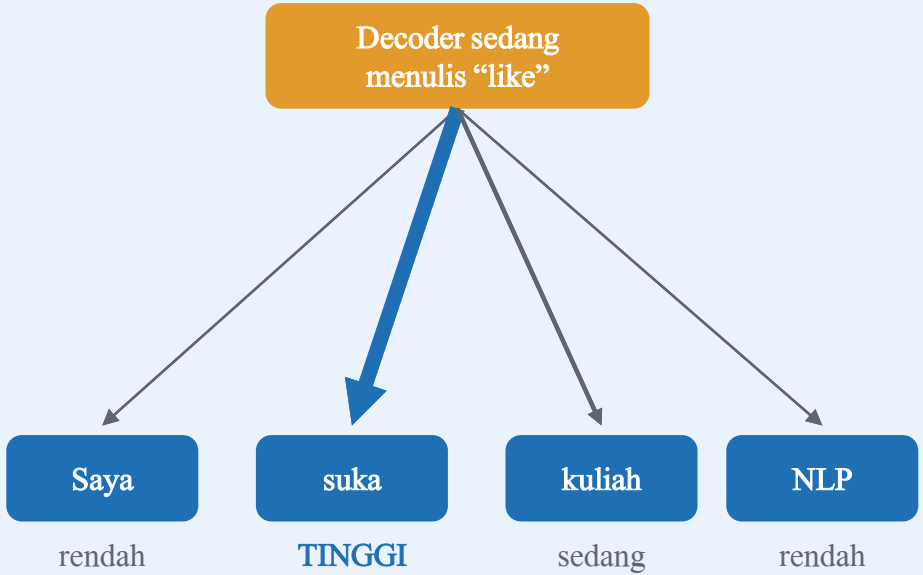
Bagaimana jika decoder boleh melihat kembali semua kata input di setiap langkah? → **Attention**

Attention Mechanism

Apa itu Attention?

- Memberi **bobot perhatian** pada tiap kata input.
- Di setiap langkah, decoder menilai kata input mana yang paling relevan.
- Kata relevan: bobot besar. Kata kurang relevan: bobot kecil.
- Context vector kini **berbeda di tiap langkah** (dinamis).

Analogi: *penerjemah manusia* ***menengok kembali*** *kalimat sumber saat menulis tiap kata.*



Hidden state encoder untuk setiap kata input

Cara Kerja Attention

1. Nilai relevansi

Bandingkan keadaan decoder saat ini dengan hidden state tiap kata input.

2. Bobot perhatian

Ubah nilai menjadi bobot yang jumlahnya 100% (softmax, seperti Pertemuan 8).

3. Context vector

Gabungkan hidden state encoder sesuai bobotnya; yang relevan berkontribusi lebih besar.

4. Prediksi kata

Context vector + keadaan decoder dipakai untuk menebak kata berikutnya.

Contoh: decoder akan menulis “like”

Saya	suka	kuliah	NLP
rendah	TINGGI	sedang	rendah

→ like

Seluruh proses diulang di setiap langkah decoder, sehingga tiap kata output punya context sendiri.

Visualisasi Attention: Matriks Alignment

Kata input (Indonesia)

	Saya	suka	kuliah	NLP
I	TINGGI	rendah	rendah	rendah
like	rendah	TINGGI	rendah	rendah
NLP	rendah	rendah	sedang	TINGGI
classes	rendah	rendah	TINGGI	sedang

Cara membaca

- Semakin gelap sel, semakin besar perhatian.
- Tiap baris = satu kata output; tiap kolom = satu kata input.
- “like” memperhatikan “suka”; “classes” memperhatikan “kuliah”.
- Urutan berbeda (“kuliah NLP” ↔ “NLP classes”), tetapi pasangannya tetap ditemukan.
- Peta ini membantu **menjelaskan** keputusan model.

Attention membuat model dapat diperiksa: kita bisa melihat kata sumber mana yang dipakai.

Seq2Seq Dasar vs Seq2Seq + Attention

Aspek	Seq2Seq biasa	Seq2Seq + Attention
Informasi dari encoder	Satu context vector tetap	Seluruh hidden state encoder dapat diakses
Kalimat panjang	Kualitas cenderung turun	Lebih stabil
Context vector	Sama untuk semua langkah	Berbeda di setiap langkah
Interpretasi	Sulit dilihat	Bisa divisualisasikan (alignment)
Beban komputasi	Lebih ringan	Lebih berat (melihat semua posisi input)

Jembatan ke depan: Transformer menjadikan attention komponen utama tanpa RNN, dasar BERT, GPT, dan LLM.

Machine Translation (MT)

MT menerjemahkan teks dari bahasa sumber ke bahasa target secara otomatis. Model belajar dari **korpus paralel**, yaitu pasangan kalimat sumber dan terjemahannya.



Tantangan Utama :

Ambiguitas kata

“bisa” = mampu (can) atau racun (venom). Maknanya bergantung pada konteks.

Urutan kata berbeda

“rumah besar” → “big house”. Susunan frasa tidak sama antar bahasa.

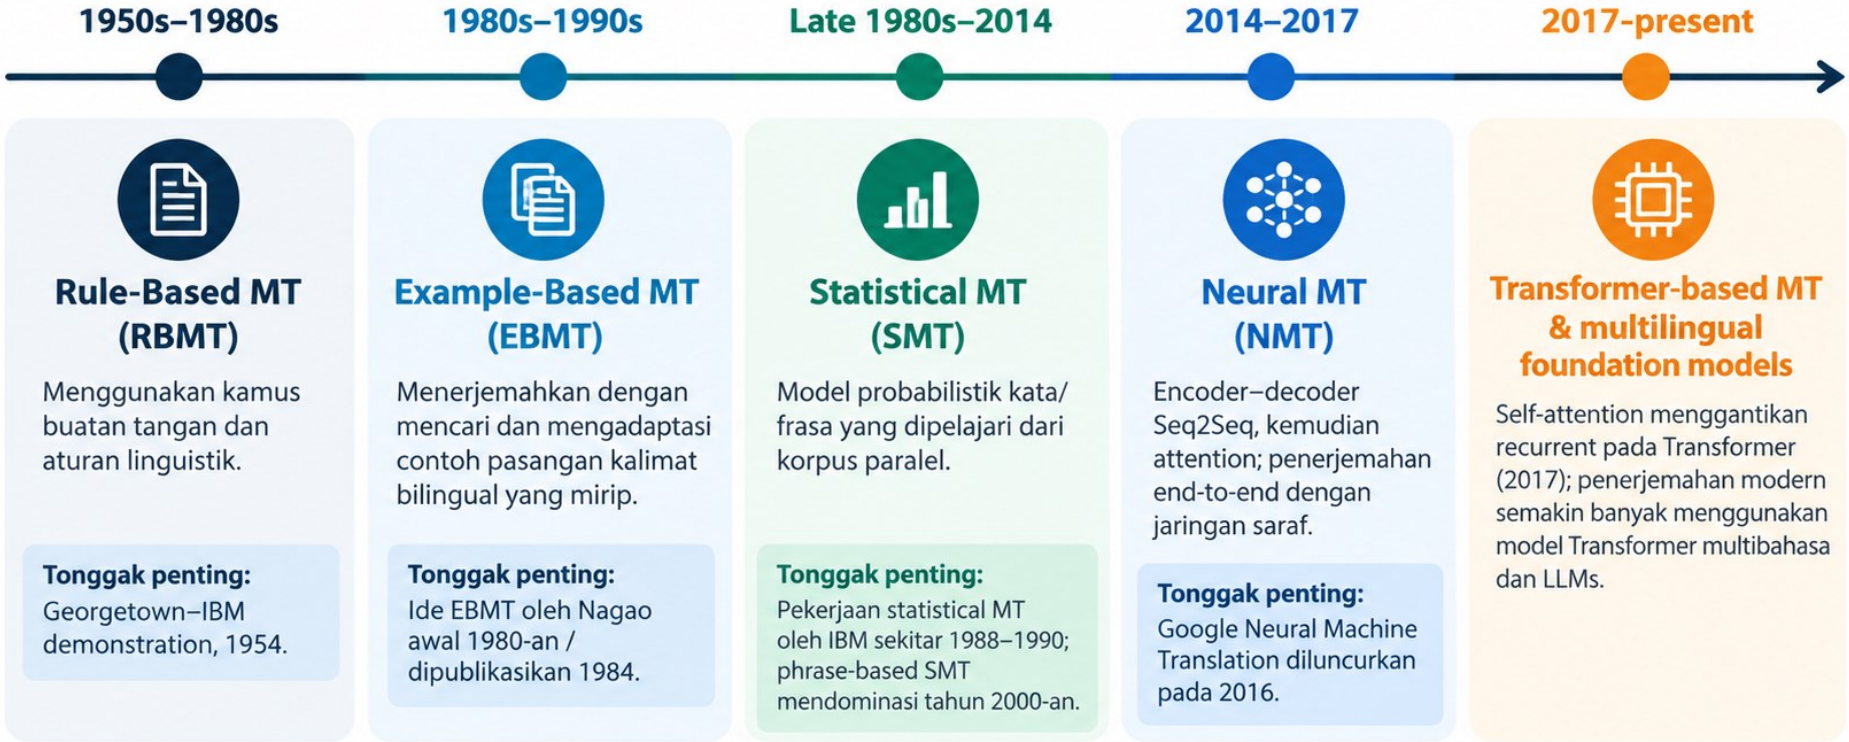
Idiom & budaya

“kepala batu” bukan “stone head”, melainkan “stubborn” (keras kepala).

Bahasa minim data

Bahasa daerah (Jawa, Sunda) kekurangan korpus paralel sehingga sulit dilatih.

Evolusi Machine Translation



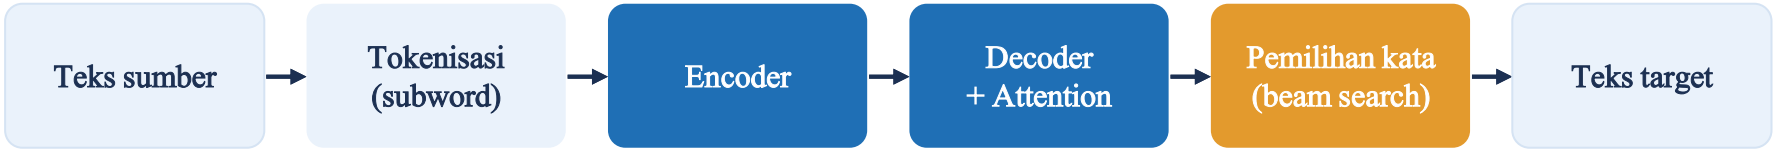
Perbandingan Pendekatan MT

Pendekatan	Cara Kerja Singkat	Contoh Sederhana
Rule-Based MT (RBMT)	Menerjemahkan berdasarkan kamus + aturan tata bahasa yang ditulis manusia	rumah besar → sistem punya aturan adjektiva Inggris di depan noun → *big house*
Example-Based MT (EBMT)	Mencari contoh kalimat serupa dari database terjemahan lalu mengadaptasinya	Database punya Saya makan nasi → *I eat rice*; input baru Saya makan roti → pola diadaptasi menjadi *I eat bread*
Statistical MT (SMT)	Memilih terjemahan berdasarkan probabilitas kata/frasa dari parallel corpus	Dari korpus, selamat pagi paling sering berpasangan dengan *good morning*, sehingga sistem memilih frasa itu
Neural MT (NMT)	Encoder membaca seluruh kalimat, decoder menghasilkan terjemahan berdasarkan representasi konteks	Saya tidak suka film itu → encoder memahami sequence → decoder menghasilkan *I don't like that movie*
Transformer-based MT	Menggunakan self-attention untuk melihat hubungan semua token secara langsung	Pada Saya duduk di *bank* sungai, attention membantu memahami bank sebagai *riverbank*, bukan financial bank

Kelebihan dan Kekurangan Pendekatan MT

Pendekatan	Kelebihan	Kekurangan
Rule-Based	Hasil dapat diprediksi; tanpa data besar	Mahal, sulit diperluas, kaku pada variasi bahasa
Statistical	Belajar otomatis dari data; lebih luwes	Terjemahan per frasa; kurang lancar
Neural (Seq2Seq + Attention)	Lebih lancar; konteks kalimat lebih baik	Butuh data dan komputasi besar; sulit diinterpretasi
Transformer / LLM	Konteks panjang; banyak bahasa dalam satu model	Biaya tinggi; bisa halusinasi dan bias

Neural MT: Alur & Evaluasi



Contoh Hasil Terjemahan

✓ “Dia membeli buku di toko itu.” → “He bought a book at that store.”

✗ “Dia kepala batu.” → “He is stone head.” (harfiah, keliru)

✓ “Dia kepala batu.” → “He is stubborn.” (sesuai makna)

Idiom sering keliru bila model hanya menerjemahkan kata per kata.

Cara Menilai Kualitas

- **BLEU:** membandingkan potongan kata (n-gram) hasil mesin dengan terjemahan referensi; makin banyak yang cocok, makin tinggi.
- **Evaluasi manusia:** kelancaran (fluency) dan kesetiaan makna (adequacy).
- **Metrik berbasis embedding:** menilai kemiripan makna.
- Skor tinggi belum tentu berarti makna benar.

Chatbot

Chatbot adalah program yang berinteraksi dengan manusia melalui percakapan teks atau suara.



Rule-based

Cara: aturan if–then, pola kata kunci, template.

+ Terprediksi, mudah dikontrol.

– Kaku; tiap kasus butuh aturan manual.

Retrieval-based

Cara: memilih jawaban terbaik dari kumpulan jawaban/FAQ.

+ Jawaban rapi dan aman.

– Tidak bisa menjawab di luar basis jawaban.

Generative

Cara: menyusun jawaban baru kata demi kata (Seq2Seq / LLM).

+ Fleksibel dan natural.

– Bisa salah fakta (halusinasi); butuh data besar.

Chatbot modern sering menggabungkan ketiganya (hybrid).

Evolusi Chatbot

1960-an–1980-an



Pencocokan Pola

Chatbot awal berbasis aturan sederhana dan kata kunci.

Contoh:
ELIZA (1966), PARRY (1972)

Batas:
belum memahami makna secara mendalam.

1990-an–2000-an



Rule-Based Skala Besar

Menggunakan pola percakapan yang lebih banyak dan basis aturan yang lebih luas.

Contoh:
A.L.I.C.E. (1995), SmarterChild (2001)

Batas:
aturan makin banyak dan sulit dirawat.

2010-an



Asisten Virtual

Mulai memanfaatkan intent, entity, dan dialog untuk tugas tertentu.

Contoh:
Siri (2011), Alexa (2014), Google Assistant (2016)

Batas:
kuat pada tugas spesifik, belum sangat fleksibel.

2015–2019



Neural Generatif

Chatbot mulai memakai Seq2Seq, LSTM, dan attention untuk menghasilkan respons.

Contoh:
Neural Conversational Model (2015)

Batas:
respons sering generik dan konteks pendek.

2020–kini



LLM

Berbasis Transformer, pretraining besar, dan instruction tuning sehingga percakapan lebih natural.

Contoh:
ChatGPT (2022), Gemini, Claude, Copilot

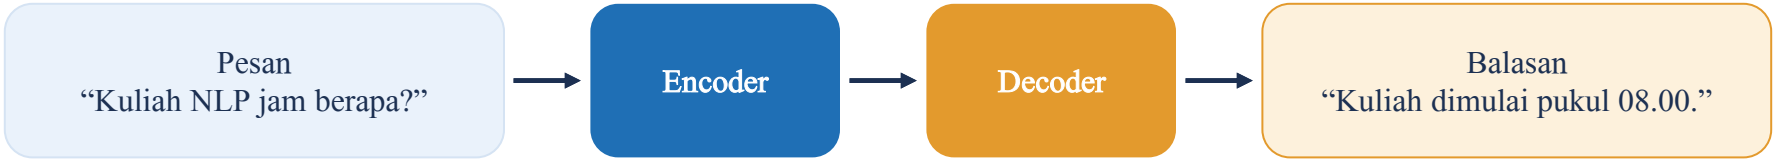
Batas:
halusinasi, bias, biaya komputasi, dan isu keamanan.

Satu Pertanyaan pada Berbagai Generasi Chatbot

“Saya sedang stres karena tugas kuliah menumpuk. Apa yang harus saya lakukan?”

Jenis chatbot	Contoh keluaran
Pencocokan Pola — ELIZA / PARRY	“Mengapa Anda merasa stres?”
Rule-Based skala besar — A.L.I.C.E. / SmarterChild	“Jika Anda merasa stres, cobalah beristirahat dan menyelesaikan tugas satu per satu.”
Asisten Virtual — Siri / Alexa / Google Assistant	“Saya dapat membantu membuat pengingat atau jadwal untuk tugas Anda.”
Neural Generatif — Seq2Seq / LSTM / Attention	“Cobalah fokus pada satu tugas terlebih dahulu dan beri waktu istirahat di antaranya.”
LLM — ChatGPT / Gemini / Claude / Copilot	“Mulailah dengan membuat daftar semua tugas, urutkan berdasarkan deadline dan tingkat kesulitan, lalu kerjakan satu per satu. Misalnya, bagi waktu menjadi blok 25–30 menit dengan jeda singkat. Jika ada tugas yang paling mendesak, selesaikan itu terlebih dahulu.”

Chatbot Berbasis Seq2Seq



Cara Kerja

- Riwayat percakapan digabung dengan pesan terbaru sebagai input agar konteks terjaga.
- Decoder menghasilkan balasan kata demi kata.
- Dilatih dari pasangan (pesan → balasan) pada data dialog.
- Attention membantu fokus pada bagian riwayat yang penting.

Tantangan → Penanganan

- Jawaban generik (“Saya tidak tahu”) → data berkualitas, decoding lebih variatif.
- Tidak konsisten → fine-tuning pada gaya/persona.
- Halusinasi → RAG: ambil dokumen rujukan sebelum menjawab.
- Bias dan keamanan → penyaringan dan guardrail.

Text Generation

Text Generation adalah proses ketika model NLP **menghasilkan teks baru secara otomatis** berdasarkan input, prompt, atau teks sebelumnya.

Prinsip Dasar
Model memprediksi **token berikutnya** berdasarkan konteks yang sudah tersedia, lalu proses tersebut diulang secara **autoregresif** hingga kondisi berhenti tercapai.

Prompt → Prediksi token → Tambahkan token → Prediksi berikutnya → … → Teks baru

Digunakan untuk

- melanjutkan teks atau cerita;
- membuat respons chatbot;
- menghasilkan caption atau deskripsi;
- summarization;
- penulisan kreatif;
- membantu menghasilkan konten berbasis prompt.

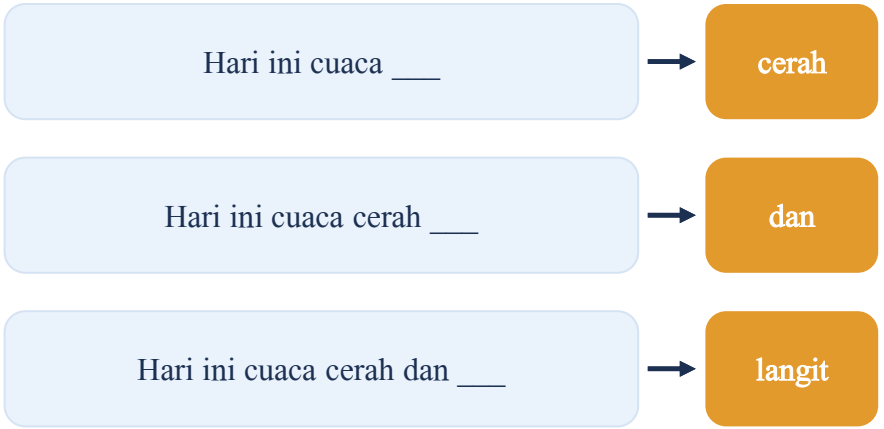
Evolusi singkat model generatif



Cara Kerja / Prinsip Dasar Text Generation

Prinsip Dasar

- Model bahasa **memprediksi kata berikutnya** dari kata-kata sebelumnya.
- Prediksi diulang, kata baru ditambahkan: disebut **autoregresif**.
- Tiap langkah: softmax atas seluruh kosakata (Pertemuan 8).



Contoh Satu Prompt pada Berbagai Model

Prompt: “Hari ini cuaca cerah dan …”

Pendekatan	Contoh keluaran
N-gram Language Model	“langit biru.”
RNN Language Model	“langit terlihat biru.”
LSTM / GRU	“langit terlihat biru sejak pagi.”
Seq2Seq + Attention	“Hari ini cuaca cerah dan langit terlihat sangat biru.”
Transformer	“Hari ini cuaca cerah dan langit terlihat sangat biru, sementara angin bertiup pelan.”
LLM	“Hari ini cuaca cerah dan langit terlihat sangat biru, sementara angin bertiup pelan sehingga suasana terasa nyaman untuk beraktivitas di luar ruangan.”

Contoh output bersifat ilustratif; tujuan utamanya menunjukkan perkembangan kemampuan model dalam memanfaatkan konteks.

Strategi Memilih Kata (Decoding)

Strategi	Cara memilih kata	Karakter hasil	Cocok untuk
Greedy	Selalu ambil kata berprobabilitas tertinggi	Cepat; bisa monoton dan berulang	Prototipe cepat
Beam search	Menyimpan beberapa kandidat urutan terbaik	Lebih akurat; cenderung aman/generik	Terjemahan, ringkasan
Sampling	Memilih acak sesuai probabilitas	Beragam dan kreatif; bisa tidak koheren	Cerita, puisi
Top-k / Top-p	Sampling dibatasi pada kandidat teratas	Seimbang antara kualitas dan variasi	Chatbot, penulisan

Temperature rendah
aman, konsisten, cenderung berulang



Temperature tinggi
kreatif, beragam, berisiko ngawur

Tugas yang butuh ketepatan memakai beam search; tugas kreatif memakai sampling.

Perbandingan Tiga Penerapan

Aspek	Machine Translation	Chatbot	Text Generation
Input	Kalimat bahasa sumber	Pesan + riwayat dialog	Prompt / awal teks
Output	Kalimat bahasa target	Balasan percakapan	Lanjutan teks bebas
Tujuan	Setia pada makna sumber	Relevan dan natural	Koheren dan kreatif
Model umum	Seq2Seq + Attention → Transformer	Seq2Seq → LLM	Language model → LLM
Evaluasi	BLEU, evaluasi manusia	Evaluasi manusia, kepuasan pengguna	Perplexity, evaluasi manusia
Tantangan utama	Idiom, ambiguitas, data langka	Jawaban generik, halusinasi	Halusinasi, repetisi, bias

Ringkasan

Seq2Seq
- Urutan → urutan
- Panjang input ≠ output
- Encoder + Decoder

Encoder–Decoder
- Encoder merangkum input
- Decoder menulis kata demi kata
- <SOS> … <EOS>

Attention
- Mengatasi bottleneck
- Bobot perhatian per langkah
- Dasar Transformer

Machine Translation
- Rule → Statistik → Neural → LLM
- Evaluasi: BLEU + manusia
- Tantangan: idiom, ambiguitas

Chatbot
- Pola → Intent → Generatif → LLM
- Rule / retrieval / generative
- Tantangan: halusinasi

Text Generation
- Prediksi kata berikutnya
- Greedy, beam, sampling
- Verifikasi hasilnya

Seq2Seq membuat model mampu menghasilkan teks; attention membuatnya fokus pada bagian yang relevan.

Excellence in Learning Innovation

Sehat
Bergerak
Berdampak
Berkelanjutan



THANK YOU!

Tugas Kelompok

Mini Project Machine Translation menggunakan Seq2Seq + Attention

Semua kelompok menggunakan:

- task yang sama: **Indonesia → Inggris**
- dataset dicari sendiri bebas oleh kelompok
- preprocessing dasar yang sama
- split data yang sama
- metrik evaluasi yang sama

Setiap kelompok diminta membangun dua model:

Model 1: Seq2Seq Encoder–Decoder tanpa Attention

Model 2: Seq2Seq Encoder–Decoder + Attention

Kemudian masing-masing kelompok wajib membandingkan kedua model dari sisi:

- kualitas terjemahan;
- kemampuan menangani kalimat panjang;
- BLEU;
- waktu training;
- contoh prediksi benar dan salah;
- visualisasi attention/alignment;
- analisis error.

Dengan pipeline:

Dataset → Tokenisasi → Padding → Encoder → Decoder → Attention → Decoding → Evaluasi