PEMROSESAN BAHASA ALAMI
Natural Language Processing

Pertemuan 11
Text Summarization, Speech Recognition & Image Captioning

NINF236023 - INTNINF236026

Dosen Pengampu: Prof. Aji Prasetya Wibawa, S.T., M.M.T., Ph.D.

M. Zainal Arifin, S.Si., M.Kom. Ph.D

Mentor: Agung Bella Putra Utama

Fadia Irsania Putri

Apa yang Akan Kita Pelajari?

Today's Topics

1. Text Summarization
2. Speech Recognition
3. Image Captioning

Peta Materi: Tiga Tugas, Satu Kerangka

Tugas	Input	Encoder	Decoder	Output	Metrik
Text Summarization (abstractive)	Teks panjang	Encoder teks	Decoder teks	Ringkasan	ROUGE
Speech Recognition	Audio (spektrogram)	Encoder audio	Decoder teks / CTC	Transkrip	WER, CER
Image Captioning	Gambar	Encoder visual (CNN / ViT)	Decoder teks	Caption	BLEU

Kerangka sama: encoder memahami input, decoder menghasilkan teks (Pertemuan 10).

Apa Text Summarization?

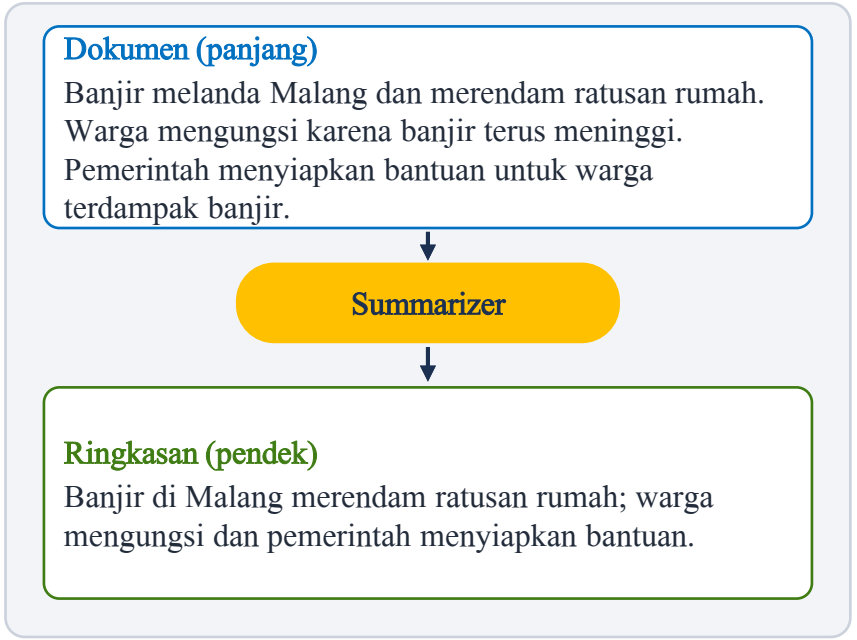
Text summarization: proses NLP untuk menghasilkan **ringkasan otomatis** dari teks panjang, dengan tetap mempertahankan makna utama dan informasi pentingnya.

Tujuannya:

- Mempercepat pemahaman dokumen panjang
- Mengurangi beban membaca
- Menyediakan “essence” dari konten

Contoh:

- Merangkum artikel berita
- Ringkasan dokumen penelitian
- Merangkum percakapan atau meeting notes
- Chatbot yang menyederhanakan jawaban panjang
- E-learning (merangkum materi kuliah)



Dua Jenis Utama Text Summarization

1. Extractive Summarization

Memilih kalimat penting dari teks asli tanpa mengubah susunan kata (seperti menyorot kalimat kunci).

Metode umum:

- TF-IDF
- TextRank
- Latent Semantic Analysis (LSA)
- BERT-based sentence ranking

Kelebihan: cepat dan sederhana.

Kekurangan: kurang natural, hanya menyalin kalimat.

2. Abstractive Summarization

Menghasilkan kalimat baru yang belum tentu ada di teks asli, seperti manusia merangkum.

Metode umum:

- Seq2Seq (LSTM encoder–decoder) + attention
- Transformer: T5, BART, PEGASUS
- Model bahasa besar (GPT)

Kelebihan: lebih natural dan koheren.

Kekurangan: kompleks, butuh data besar, bisa berhalusinasi.

Extractive memilih kalimat; abstractive menulis ulang.

Evaluasi Summarization: ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) metrik paling populer untuk evaluasi summarization.

- **ROUGE-1**
  Mengukur overlap unigram (kata) antara ringkasan model dan ringkasan referensi.

- **ROUGE-2**
  Mengukur overlap bigram (dua kata berurutan).
  Lebih sensitif terhadap koherensi frasa.

- **ROUGE-L**
  Menggunakan Longest Common Subsequence (LCS) antara prediksi dan referensi.
  Mengukur kesamaan struktur kalimat.

ROUGE biasanya dihitung dalam 3 skor:
- Precision
- Recall
- F1-score

ROUGE adalah standar utama untuk menilai kualitas ringkasan karena langsung membandingkan isi ringkasan dengan ringkasan manusia.

Hybrid Approaches untuk Summarization

Jenis hybrid	Ide singkat	Nilai inovasi	Cocok untuk
Extractive–Abstractive	Pilih kalimat penting, lalu tulis ulang	Akurat tetapi tetap natural	Berita, dokumen panjang
Knowledge-Enhanced	Terhubung ke knowledge graph / ontologi	Faktualitas naik, halusinasi turun	Medis, hukum, akademik
Topic-Guided	Diarahkan topik hasil LDA / BERTopic	Ringkasan lebih terstruktur	Artikel riset, laporan
Sentiment-Aware	Menjaga tone / sentimen sumber	Konsisten dengan emosi asli	Ulasan produk, opini
Readability-Controlled	Menyesuaikan tingkat kesulitan bahasa	Adaptif untuk audiens berbeda	Pendidikan, e-learning
Reinforcement Learning	Reward (mis. ROUGE, faktualitas)	Model belajar dari kualitas ringkasan	Model state-of-the-art

Apa Itu Speech Recognition?

- **Automatic Speech Recognition (ASR)**: mengubah sinyal suara menjadi **teks**.
- Input berupa urutan sinyal audio yang sangat panjang; output berupa urutan kata atau karakter → masalah **sequence-to-sequence**.
- Tantangan: aksen, derau, kecepatan bicara, bahasa daerah, dan campur kode.

Contoh aplikasi

- Asisten suara
- Subtitle otomatis
- Transkripsi rapat dan kuliah
- Aksesibilitas bagi tunarungu

Pipeline :



Speech recognition = audio → fitur → model → teks.

Pendekatan Speech Recognition

Pendekatan	Komponen	Catatan
Tradisional	Model akustik (GMM/DNN-HMM) + kamus pelafalan + model bahasa	Beberapa komponen terpisah; butuh lexicon
CTC	Encoder (RNN / Transformer) + loss CTC; keluaran per frame	Tanpa penyelarasan manual; contoh: wav2vec 2.0 yang di-fine-tune
Attention encoder–decoder	Encoder audio + decoder autoregresif (mis. Listen, Attend and Spell)	Seperti Seq2Seq Pertemuan 10; contoh: Whisper
RNN-Transducer	Encoder + prediction network + joint network	Cocok untuk pengenalan suara streaming

Ekstraksi Fitur Audio

Sampling & normalisasi	Framing & windowing	FFT	Filter Mel	Log (+ DCT)
• Sinyal analog didigitalkan; umum 16 kHz. • Amplitudo dinormalisasi.	• Sinyal dipotong menjadi frame pendek yang tumpang tindih. • Fungsi window (mis. Hamming) mengurangi artefak tepi.	• Mengubah tiap frame ke domain frekuensi (spektrum).	• Frekuensi dikelompokkan menurut skala Mel yang meniru pendengaran manusia.	• Log-Mel spektrogram: umum untuk model neural. • MFCC: log-Mel ditambah DCT.

Hasil: urutan vektor fitur (satu per frame) → masukan encoder.

Model modern (mis. wav2vec 2.0) juga dapat belajar langsung dari gelombang mentah tanpa fitur buatan tangan.

Evaluasi Speech Recognition: WER dan CER

$$WER = (S + D + I) / N$$

S • Substitusi
kata salah diganti kata lain

D • Delesi
kata pada referensi hilang

I • Insersi
kata tambahan yang tidak ada

N
jumlah kata pada referensi

Catatan

- WER diperoleh dari jarak edit (Levenshtein) tingkat kata; semakin kecil semakin baik.
- WER dapat melebihi 100% karena insersi ikut dihitung.
- **CER** memakai prinsip yang sama pada tingkat karakter; berguna untuk bahasa tanpa spasi atau nama diri.

Pertimbangkan juga kecepatan (latensi) dan ketahanan terhadap derau dan aksen.

Kendala Speech Recognition

Variasi penutur

Aksen, usia, kecepatan, dan intonasi sangat beragam.

Solusi: data beragam, augmentasi (SpecAugment), adaptasi penutur.

Derau & lingkungan

Bising latar, gema, dan mikrofon murah menurunkan akurasi.

Solusi: augmentasi derau, peningkatan sinyal, model tangguh.

Bahasa terbatas data

Bahasa daerah dan campur bahasa (mis. Indonesia–Inggris) minim data.

Solusi: pralatih self-supervised, model multibahasa, transfer learning.

Istilah & nama khusus

Nama orang, istilah teknis, dan singkatan sering salah dikenali.

Solusi: contextual biasing, model bahasa domain, subword.

Ucapan spontan

Jeda, pengulangan, dan penutur yang tumpang tindih sulit dikenali.

Solusi: diarization, data percakapan, model yang robust.

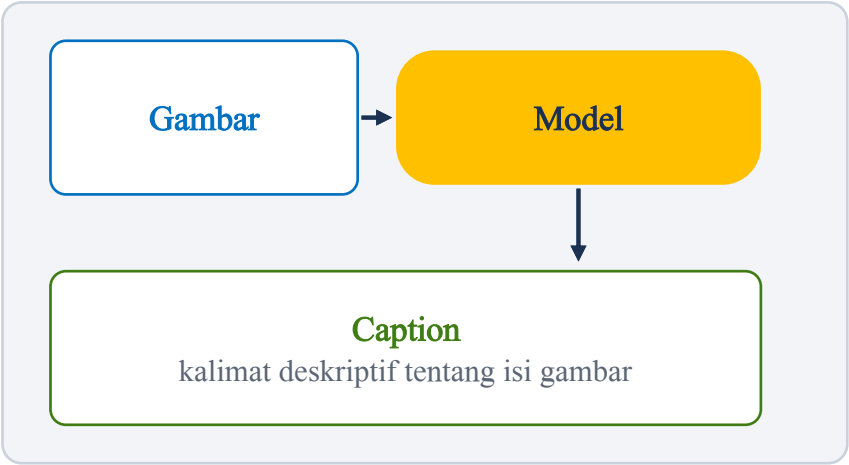
Latensi & privasi

Perlu real-time di perangkat terbatas; data suara bersifat sensitif.

Solusi: model streaming (RNN-T), kompresi, pemrosesan on-device.

Apa itu Image Captioning?

- **Image captioning**: menghasilkan **deskripsi bahasa alami** dari sebuah gambar.
- Menggabungkan **computer vision** (memahami gambar) dan **NLP** (menulis kalimat).
- Output berupa kalimat yang ditulis kata demi kata → decoder bahasa.



Contoh Aplikasi:

- Pencarian gambar
- Media sosial
- Robotik

Image captioning = gambar → fitur visual → kalimat.

Arsitektur Image Captioning

Gambar → Encoder visual → Attention → Decoder bahasa → Caption

CNN / ViT menghasilkan fitur gambar → decoder (LSTM / Transformer) menulis caption, dengan attention pada wilayah gambar.

Show and Tell

- Vinyals et al. (2015).
- CNN sebagai encoder, LSTM sebagai decoder.
- Fitur global gambar menjadi masukan awal decoder.

Show, Attend and Tell

- Xu et al. (2015).
- Attention pada wilayah (grid) gambar.
- Tiap kata fokus pada wilayah berbeda.

Model modern

- Transformer dan vision-language pralatih (mis. BLIP, ViT + GPT-2).
- Fine-tune pada MS COCO.

Sama seperti Seq2Seq + attention, tetapi encoder-nya memahami gambar.

Evaluasi Image Captioning

BLEU

- Presisi n-gram terhadap caption referensi (berasal dari machine translation).

METEOR

- Memperhitungkan sinonim dan bentuk dasar kata; menyeimbangkan presisi dan recall.

CIDEr

- Konsensus n-gram berbobot TF-IDF terhadap banyak caption referensi.

SPICE

- Menilai kecocokan objek, atribut, dan relasi lewat scene graph.

Penilaian manusia

- Relevansi, ketepatan, dan kelancaran caption.
- Melengkapi metrik otomatis.

Kendala Image Captioning

Caption generik

Model cenderung memilih kalimat umum yang aman.

Solusi: self-critical training (CIDEr), decoding yang lebih beragam.

Halusinasi objek

Menyebut objek yang tidak ada pada gambar (Rohrbach et al., 2018).

Solusi: fitur region/grounding, penalti halusinasi, metrik CHAIR.

Detail halus & relasi

Sulit menghitung objek, posisi spasial, dan membaca teks di gambar.

Solusi: fitur region, resolusi lebih tinggi, OCR, model multimodal.

Evaluasi sulit

Banyak caption benar; metrik n-gram kurang menangkap makna.

Solusi: banyak referensi, CIDEr/SPICE, CLIPScore, penilaian manusia.

Bias dataset

Data seperti MS COCO bias pada gender, budaya, dan situasi tertentu.

Solusi: kurasi dan audit data, evaluasi bias, data lebih beragam.

Bahasa & konteks lokal

Dataset caption bahasa Indonesia terbatas; objek dan budaya lokal kurang terwakili.

Solusi: data lokal, fine-tune multibahasa, terjemahan + validasi manusia.

Kendala utama captioning: kesetiaan pada isi gambar, keragaman, dan evaluasi.

Excellence in Learning Innovation

Sehat
Bergerak
Berdampak
Berkelanjutan



THANK YOU!

Tugas lanjutan Pertemuan 10

Mini Project Chatbot FAQ Bahasa Indonesia

Setiap kelompok diminta membangun dua model:

Model 1: Chatbot Retrieval (TF-IDF + Cosine Similarity)

Model 2: Chatbot Neural Network (Intent Classifier LSTM/GRU)

Kemudian masing-masing kelompok wajib membandingkan kedua model dari sisi:

- akurasi pemilihan intent/respons;
- precision, recall, dan F1-score;
- kemampuan menangani variasi kalimat;
- waktu training;
- waktu respons;
- confusion matrix;
- contoh prediksi benar dan salah;
- analisis error, termasuk OOV dan confidence rendah.